

Laboratorio di WebScraping

BetFlow: analisi di Satoshi Dice, un servizio di betting su Bitcoin

Francesco Lioni

Matricola: 658189

1. Caricamento dei Dataset e Gestione delle Risorse

L'importazione dei dataset è stata progettata per minimizzare il consumo di RAM e velocizzare i tempi di caricamento dei dataset. Sono state ottimizzate **3 caratteristiche principali**:

1. Data Downcasting (Riduzione dei tipi di dato)

Di default, Pandas assegna formati a 64 bit molto pesanti. Per ridurre l'impronta in memoria si è applicato un mapping esplicito (`dtypes`) prima della lettura:

- **int32 e int16** : Applicati a ID e contatori spaziali/temporali (`timestamp` , `txId` , `addressId` , `position`) per dimezzare o ridurre a un quarto lo spazio occupato, senza rischio di overflow.
- **float32 vs float64** : Le tariffe (`fee`) e i puntatori (`prevTxId` , `prevTxpos`) sono stati ridotti a 32 bit (necessari per supportare i valori nulli degli input *Coinbase*). Solo l'attributo `amount` è stato mantenuto a 64 bit (`float64`) per evitare qualsiasi perdita di precisione sui decimali dei Satoshi.
- **category** : Utilizzato per `isCoinbase` , riduce drasticamente il peso della variabile mappando internamente i valori univoci rispetto all'uso di stringhe o interi classici.

2. Scelta dei Motori di Parsing

- **PyArrow**: I file principali sono stati letti con `engine='pyarrow'` (in C++), sfruttando il multi-threading per abbattere i tempi di caricamento di file di grandi dimensioni.
- **Python Engine**: Il file `satoshiDiceInfos.tsv` presenta separatori irregolari. Per parsarlo correttamente è stata utilizzata l'espressione regolare `r'\t+|\s{2,}'` .

3. Feature Selection a Tempo Zero

Immediatamente dopo l'importazione, la colonna `scripttype` è stata rimossa (`outputs.drop`). Essendo irrilevante ai fini della costruzione del grafo, scartarla subito permette di liberare prezioso spazio in RAM per le successive operazioni di *join*.

2. Analisi dell'Incidenza delle Transazioni di Bet sul Traffico Globale (Scelte Tecniche)

Il primo obiettivo dell'analisi generale richiede di calcolare e contestualizzare l'impatto di Satoshi Dice sull'intera rete Bitcoin, misurando la percentuale di transazioni di *bet* rispetto al volume complessivo del traffico *on-chain*, osservato sotto diverse granularità temporali.

Per rispondere a questa richiesta, la preparazione dei dati e l'elaborazione analitica sono state suddivise nei seguenti passaggi logici:

1. Identificazione e Flagging delle Bet

Poiché Satoshi Dice non richiede registrazione, ogni scommessa è identificabile esclusivamente tramite l'indirizzo di destinazione. Sfruttando il file di mapping, sono stati filtrati e isolati gli `addressId` associati ai *vanity address* del servizio (riconoscibili dal prefisso `1dice`). Successivamente, incrociando questi ID con la tabella degli `outputs`, è stato possibile estrarre gli identificatori univoci (`txId`) delle transazioni contenenti almeno una puntata diretta al servizio. Infine, la tabella principale delle transazioni è stata arricchita con una variabile booleana (`is_bet`), fondamentale per le successive aggregazioni.

2. Pre-processing Temporale

I `timestamp` nativi dei blocchi, originariamente espressi nel tempo UNIX, sono stati convertiti in formato `datetime` per permettere l'indicizzazione temporale del dataset. L'analisi è stata focalizzata sull'anno **2012**; tale scelta è coerente con il ciclo di vita del servizio, il cui lancio ufficiale è avvenuto in tale anno, risultando in un'incidenza nulla del traffico nei periodi precedenti (inclusi nel dataset a partire dal blocco genesis del 2009).

3. Calcolo delle Metriche e Aggregazione (Resampling)

Per valutare l'andamento nel tempo, la serie storica è stata ricampionata (tramite la funzione `resample` di Pandas) calcolando aggregazioni su tre diverse finestre temporali:

- **Giornaliera (D)**
- **Settimanale (W)**
- **Mensile (ME)**

Per ciascun periodo, è stata calcolata l'incidenza percentuale matematica:

$$\text{Percentuale Bet} = \left(\frac{\text{Somma delle Transazioni di Bet}}{\text{Conteggio Totale delle Transazioni}} \right) \times 100$$

4. Smoothing delle Serie Storiche (Rolling Window)

Dato che il traffico giornaliero su blockchain presenta una forte volatilità, per i dati a


granularità giornaliera è stata applicata una **media mobile a 14 giorni (Rolling Window)**. Tale scelta è finalizzata a filtrare il rumore stocastico e le fluttuazioni, permettendo di isolare il trend di crescita effettivo e rendendo la curva di tendenza più leggibile rispetto al dato grezzo.

5. Scelte di Visualizzazione

Per la rappresentazione visiva si è optato per una griglia di tre grafici a linee (*lineplot*) sovrapposti e con asse Y condiviso. Questa configurazione permette di:

- Valutare istantaneamente il macro-trend mensile, evidenziando la rapidissima adozione del servizio nel corso del 2012.
- Analizzare la volatilità a breve termine tramite la granularità settimanale e giornaliera.
- Notare l'entità dei volumi grazie all'area colorata (*fill_between*) che restituisce un immediato impatto visivo del "peso" di Satoshi Dice sulla blockchain di Bitcoin.

Percentuale di Transazioni di Bet nel 2012



Osservazioni e Risultati

L'esame visivo delle serie storiche restituisce una chiara fotografia dell'impatto esplosivo di Satoshi Dice sull'ecosistema Bitcoin nel corso del 2012. L'analisi del trend, supportata dall'applicazione della media mobile a 14 giorni per filtrare la volatilità giornaliera, permette di identificare tre fasi distinte:

1. **Fase di inattività/Lancio (Gennaio - Aprile 2012):** Nei primi quattro mesi dell'anno, l'incidenza delle scommesse è nulla. Questo riflette la fase antecedente al lancio o alla diffusione capillare del servizio sulla rete.
2. **L'esplosione dei volumi (Maggio - Giugno 2012):** Tra la fine di aprile e l'inizio di maggio si osserva un'impennata quasi verticale del traffico. Il grafico giornaliero mostra che, in alcune giornate di picco, oltre il **40%** di tutte le transazioni mondiali su blockchain Bitcoin era costituito da *bet* verso gli indirizzi di Satoshi Dice.
3. **Stabilizzazione strutturale (Luglio - Dicembre 2012):** Dopo una fisiologica flessione nel mese di luglio, i volumi si assestano su una configurazione permanente. Analizzando il grafico mensile, emerge un dato di rilievo: per tutta la seconda metà del 2012, il servizio ha mantenuto una quota di mercato costante, generando costantemente **tra il 20% e il 30%** dell'intero traffico globale della rete.

Infine, il confronto tra le diverse granularità temporali si rivela essenziale: mentre il dato **giornaliero** evidenzia un'altissima volatilità stocastica, l'integrazione della media mobile a 14 giorni e i raggruppamenti **settimanali e mensili** filtrano efficacemente il "rumore" statistico. Tale sintesi conferma che Satoshi Dice non è stato un fenomeno passeggero, al contrario è stato capace di consolidarsi strutturalmente come uno dei principali pilastri del traffico *on-chain* dell'intero 2012.

3. Popolarità degli Indirizzi di Betting (Scelte Tecniche)

Il secondo obiettivo dell'analisi generale richiede di misurare il successo e la popolarità dei vari indirizzi (identificati dal prefisso `1dice`) messi a disposizione da Satoshi Dice. Per fornire una panoramica completa, la popolarità è stata misurata seguendo due metriche distinte:


1. **Frequenza di utilizzo:** il numero totale di scommesse ricevute da ciascun indirizzo.
2. **Volume monetario:** l'ammontare complessivo (`amount`) trasferito verso ciascun indirizzo.

Per raggiungere questo scopo e preparare i dati alla visualizzazione, il codice è stato strutturato nei seguenti passaggi:

- **Aggregazione dei Dati:** partendo dal dataframe `bet_outputs` (precedentemente filtrato), le transazioni sono state raggruppate per `addressId` . tramite la funzione `agg()` , sono state estratte simultaneamente le due metriche richieste: il conteggio

delle scommesse (`num_bet`) e la somma degli importi giocati (`tot_amount`).

- **Mapping e denominazione:** l'ID numerico dell'indirizzo è scarsamente comunicativo. Pertanto, la tabella aggregata è stata unita prima al dataframe di `mapping` per recuperare l'hash originale dell'indirizzo, e successivamente al file contenente i metadati di Satoshi Dice. Questo ha permesso di associare a ogni barra del grafico la rispettiva etichetta `Name` (es. *"lessthan 64000"*, che descrive la condizione di vincita del gioco), rendendo la lettura dei risultati immediata.
- **Conversione di Valuta:** l'importo aggregato (`tot_amount`), nativamente espresso in Satoshi, genererebbe numeri interi con troppe cifre, rendendo l'asse X illeggibile. Prima della visualizzazione, il volume totale è stato diviso per 10^8 , convertendolo formalmente in Bitcoin (BTC).
- **Scelte di Visualizzazione:** si è optato per due **grafici a barre orizzontali** (bar chart) affiancati. La scelta dell'orientamento orizzontale è ottimale quando si gestiscono categorie testuali relativamente lunghe (come i nomi delle bet), in quanto evita l'accavallamento delle etichette sull'asse X. Inoltre, l'ordinamento forzato facilita il confronto visivo tra le due metriche.



Osservazioni e Risultati:

L'analisi visiva dei due grafici a barre affiancati rivela pattern comportamentali molto netti da parte degli utenti di Satoshi Dice, evidenziando una fortissima correlazione tra la frequenza delle giocate e i volumi monetari movimentati.

Dall'osservazione emergono i seguenti punti chiave:

1. **Il predominio assoluto di "lessthan 32000":** Questo specifico indirizzo (che rappresenta una precisa condizione di probabilità e moltiplicatore di vincita) è il preferito dai giocatori. Domina entrambe le classifiche, registrando un numero di

scommesse (circa 800.000) e un volume generato (oltre 500.000 BTC) nettamente superiori a qualsiasi altra opzione disponibile.

2. **Allineamento della Top 3:** Le preferenze degli utenti sono altamente concentrate. Le prime tre posizioni del podio sono identiche in entrambi i grafici: `lessthan 32000`, `lessthan 32768` e `lessthan 48000`. Questo indica che i giocatori ad alti volumi e i giocatori casuali tendono a preferire esattamente le stesse meccaniche di rischio/rendimento.
3. **Distribuzione a "Coda Lunga":** Entrambi i grafici presentano una distribuzione fortemente asimmetrica. A fronte di pochissimi indirizzi che generano la quasi totalità del traffico e dei volumi (situati nella parte alta dei grafici), esiste una lunghissima "coda" di indirizzi (come `lessthan 2`, `lessthan 4`, `lessthan 8`) che risultano quasi del tutto ignorati dall'utenza, registrando un numero di interazioni e di BTC scommessi prossimo allo zero.

In conclusione, l'utenza di Satoshi Dice non distribuiva il proprio capitale in modo uniforme tra le varie scommesse offerte, ma convergeva in massa verso un sottoinsieme ristrettissimo di opzioni, verosimilmente quelle percepite come il miglior compromesso tra probabilità di vittoria e ritorno atteso.

relazione


4. Distanza tra Transazioni di Bet e Payout (Scelte Tecniche)

Il terzo obiettivo dell'analisi generale mira a valutare la latenza del servizio Satoshi Dice, misurando la distanza in termini di tempo e di blocchi tra il momento in cui un utente invia una scommessa (bet) e il momento in cui il sistema on-chain eroga il pagamento.

Per ricostruire questo legame logico, il codice si appoggia all'architettura a UTXO (Unspent Transaction Output) di Bitcoin. I passaggi analitici sono i seguenti:

Collegamento Logico (UTXO Matching): Una transazione di payout è considerata associata a una transazione di bet se un input della transazione di payout consuma un UTXO (output non speso) generato dalla transazione di bet originale. Operativamente, è stata effettuata una *inner join* tra la tabella `bet_outputs` e la tabella `inputs`. Il matching si basa su una chiave composta: l'identificatore della transazione (`txId`) e la posizione dell'output (`position`) devono coincidere esattamente con la transazione precedente (`prevTxId`) e la posizione di origine (`prevTxpos`) dichiarate nell'input speso. **Recupero delle Metriche Temporal e Spaziali:** Una volta accoppiate la transazione di origine e quella di destinazione, il dataframe risultante è stato incrociato due volte con la tabella principale `transactions` per estrarre l'altezza del blocco (`blockId`) e il tempo di mining (`timestamp`) di entrambe le operazioni.

- **Calcolo della Distanza:** Sono state calcolate due metriche differenziali per ogni singola coppia bet-payout:
 1. **Distanza in blocchi:** calcolata come differenza matematica tra `block_payout` e `block_bet`.
 2. **Distanza temporale:** calcolata come differenza tra i timestamp e divisa per 60 per esprimerla in minuti.
- **Scelte di Visualizzazione e Filtraggio Outlier:** Essendo il processo di payout automatizzato, la distribuzione dei dati presenta una fortissima asimmetria, con la stragrande maggioranza dei valori concentrata verso lo zero. Per questo motivo, entrambi i grafici adottano una **scala logaritmica sull'asse Y** (fondamentale per non schiacciare visivamente i valori meno frequenti). Per esplorare a fondo il dataset e analizzare anche la "coda lunga" delle operazioni ritardate, i grafici mostrano una finestra visiva allargata fino a 60 blocchi di distanza e 10 ore (600 minuti) di attesa.



Osservazioni e Risultati

L'analisi visiva delle distribuzioni spaziali (distanza in blocchi) e temporali (minuti)

evidenzia l'efficienza di Satoshi Dice. Entrambi i grafici mostrano un netto decadimento esponenziale, da cui si possono trarre tre conclusioni fondamentali sul funzionamento del servizio:

1. **Reattività Istantanea (Distanza Temporale):** L'istogramma temporale presenta un picco enorme in corrispondenza dei primissimi minuti (0-2 min). Tenendo conto della scala logaritmica sull'asse Y, questo significa che la stragrande maggioranza delle vincite o delle transazioni di resto veniva elaborata e trasmessa alla rete nel giro di pochissimi secondi dalla ricezione della bet.
2. **Inclusione Simultanea (Distanza in Blocchi):** Il grafico a barre conferma questa altissima reattività. La frequenza dominante si attesta sulla "distanza 0". Ciò indica che il bot di Satoshi Dice trasmetteva il payout così rapidamente che i miner della rete Bitcoin facevano in tempo a inserire *sia* la transazione di bet *sia* la relativa transazione di payout all'interno dello **stesso identico blocco**.
3. **Analisi della "Coda Lunga" (Outlier):** Grazie all'estensione del grafico fino a 60 blocchi, è possibile osservare una coda persistente di transazioni in ritardo. Payout avvenuti dopo 3-10 ore (e distanti 20-60 blocchi) non sono anomalie di calcolo, ma rappresentano dinamiche reali della blockchain, come la temporanea congestione della rete Bitcoin.

5. Analisi Dettagliata sui Top 3 Indirizzi: Distribuzione Temporale (Scelte Tecniche)

Il quarto obiettivo del progetto richiede di restringere l'analisi ai soli 3 indirizzi risultati più popolari nel punto precedente, al fine di esaminare i pattern comportamentali dei giocatori e studiare come le loro puntate si distribuiscono nel corso del tempo.

Per preparare i dati a questa analisi multi-livello, il codice è stato organizzato nei seguenti step logici:

- **Filtraggio e Arricchimento del Dato:** Tramite l'operazione `.tail(3)` applicata al dataframe ordinato per popolarità, sono stati isolati gli ID dei tre indirizzi dominanti. Una sequenza di operazioni di `merge` (inner e left join) ha permesso di incrociare questi ID con le tabelle delle scommesse e delle transazioni, recuperando l'esatto momento di esecuzione (`datetime`), le commissioni pagate (`fee`) e l'etichetta testuale della giocata (`Name`).
- **Rifattorizzazione temporale:** Il timestamp assoluto non è adatto per studiare la stagionalità. Pertanto, utilizzando le proprietà dell'accessore `.dt` di Pandas, la marca temporale è stata scomposta in tre nuove variabili cicliche e categoriche: l'ora del giorno (`hour`), il giorno della settimana (`day_name`) e il mese dell'anno (`month`).
- **Scelte di Visualizzazione:** Si è optato per una dashboard verticale composta da tre countplot a barre raggruppate (`countplot` con parametro `hue='Name'`). Questa

impostazione grafica è ideale per confrontare simultaneamente i volumi dei tre indirizzi all'interno del medesimo intervallo temporale

- **Gestione degli Assi e degli Spazi Vuoti:** Nei grafici giornaliero e mensile è stato forzato tramite il parametro `order` un ordinamento cronologico assoluto (da Lunedì a Domenica e da Gennaio a Dicembre). In questo modo, l'asse X rispetta la naturale percezione del tempo umano, costringendo il grafico a mostrare anche i mesi in cui il volume di gioco era pari a zero (Gennaio - Aprile), evitando che Pandas ordinasse le barre casualmente .

Distribuzione Temporale delle Bet (Top 3 Indirizzi)



Osservazioni e Risultati

L'esame della distribuzione temporale (oraria, giornaliera e mensile) conferma il predominio assoluto dell'indirizzo `less than 32000`.

Dall'osservazione dei tre grafici emergono i seguenti tratti:

1. **Traffico Globale e Ininterrotto (Distribuzione Oraria):** Il grafico delle ore (calcolato in UTC) mostra un flusso di giocate estremamente costante nell'arco di tutte le 24 ore. Non esistono vere e proprie "ore morte". Le leggere fluttuazioni (con lievi picchi nelle ore centrali della giornata e piccoli cali intorno alle 7-8 del mattino) suggeriscono che la base utenti di Satoshi Dice fosse distribuita a livello globale su fusi orari differenti, sfruttando appieno la natura *always-on* della blockchain di Bitcoin.
2. **Il Picco di Inizio Settimana (Distribuzione Giornaliera):** Le giocate su Satoshi Dice si mantengono alte durante i giorni feriali, registrando un picco massimo di attività il **Lunedì**. Durante il fine settimana (Sabato e Domenica) si osserva invece una leggera flessione dei volumi.
3. **L'Anomalia di Giugno (Distribuzione Mensile):** Il grafico mensile conferma il macro-trend già osservato nell'analisi generale, ma aggiunge un dettaglio: l'esplosione di volumi registrata a **Giugno 2012** è stata guidata quasi esclusivamente dalle giocate sull'indirizzo `1essthan 32000`, che in quel singolo mese ha superato la soglia delle 200.000 scommesse. Nei mesi successivi (da Agosto a Dicembre), il traffico si è stabilizzato, mantenendo comunque `1essthan 32000` come opzione nettamente preferita rispetto alle altre due.

6. Analisi di Correlazione tra Fee e Amount Scommesso (Scelte Tecniche)


Il prossimo passo dell'analisi sui tre indirizzi più popolari consiste nel verificare l'eventuale presenza di una correlazione tra l'importo scommesso dall'utente (`amount`) e la commissione di transazione volontaria pagata ai miner (`fee`). L'obiettivo è capire se i giocatori ad alti volumi tendessero a pagare commissioni più elevate per garantirsi una priorità nell'elaborazione della scommessa.

Per condurre questa indagine statistica e visiva, l'approccio è stato il seguente:

- **Calcolo dell'Indice di Correlazione:** Il dataset filtrato è stato raggruppato in base all'indirizzo di destinazione (`Name`). Per ciascun gruppo, è stato calcolato il coefficiente di correlazione tramite la funzione nativa `.corr()`.
- **Scelte di Visualizzazione (Scatter Plot):** Per rappresentare la correlazione tra questi due dati è stato scelto uno Scatter Plot. È stata predisposta una griglia orizzontale formata da tre grafici affiancati (1 riga, 3 colonne), in modo da isolare il comportamento degli utenti per ciascun tipo di giocata.
- **Gestione dell'Overplotting:** Considerata l'enorme mole di dati, stampare punti opachi avrebbe generato blocchi di colore indistinguibili (*overplotting*). Per risolvere il problema, è stato impostato un livello di trasparenza elevato (`alpha=0.3`) unito a un bordo sottilissimo. Questa accortezza permette di visualizzare la reale "densità" dei dati: le aree visivamente più marcate indicano la sovrapposizione di migliaia di scommesse con valori identici, rivelando i cluster comportamentali più frequenti.

- **Iniezione Dinamica dei Dati:** Il valore esatto della correlazione matematica (arrotondato a tre cifre decimali) è stato inserito all'interno del titolo di ogni singolo asse per facilitare il confronto immediato tra l'impatto visivo e il riscontro analitico reale.

Correlazione tra Fee e Amount per i Top 3 Indirizzi



Osservazioni e Risultati:

L'esame visivo degli scatter plot e l'analisi quantitativa del coefficiente di correlazione portano a una conclusione : **non esiste alcuna correlazione lineare** tra l'importo della scommessa e la commissione pagata ai miner.

Dalla lettura dei grafici emergono le seguenti evidenze tecniche:

1. **Assenza di Correlazione:** I valori calcolati per i tre indirizzi (0.012, 0.002 e 0.005) sono statisticamente nulli. Questo smentisce l'ipotesi secondo cui i giocatori con capitali maggiori fossero disposti a pagare fee più alte per ottenere una priorità di elaborazione sulla rete.
2. **Distribuzione a L (Clustering sugli Assi):** I punti non si dispongono lungo una diagonale, ma formano una netta figura a "L" schiacciata contro gli assi cartesiani. L'elevata trasparenza rivela che la densità massima si trova in prossimità dell'origine (basso importo, bassa fee), indicando che la stragrande maggioranza degli utenti si limitava a utilizzare la fee minima.
3. **Comportamento degli Outlier:** Si notano due tipi di comportamenti anomali ma slegati tra loro. Da un lato, scommesse enormi accompagnate da fee prossime allo zero (punti allungati sull'asse X). Dall'altro, scommesse irrisorie per le quali sono state pagate fee inspiegabilmente alte (punti verticali sull'asse Y). Quest'ultimo fenomeno è probabilmente imputabile a errori manuali di digitazione da parte degli utenti.

In conclusione, l'altissima reattività del bot di satoshidice rendeva del tutto superfluo per l'utente pagare i miner con fee maggiorate per velocizzare la scommessa.


7. Analisi Dettagliata sui Top 3 Indirizzi: Intervallo tra Bet Consecutive (Scelte Tecniche)

L'ultimo passaggio dell'analisi dettagliata sui tre indirizzi più popolari consiste nell'esaminare la distribuzione del tempo intercorso tra una scommessa e la successiva. Q

Per calcolare questi intervalli e preparare le visualizzazioni, il codice è stato strutturato attraverso le seguenti operazioni:

- **Ordinamento e Shift dei Dati:** Per poter confrontare due eventi consecutivi, il dataframe è stato preliminarmente ordinato in modo rigoroso per indirizzo di destinazione (`Name`) e per data di esecuzione (`datetime`). Successivamente, raggruppando per indirizzo, è stata utilizzata la funzione `.shift(1)` per far "slittare" la colonna del tempo temporale di una riga verso il basso. Questa tecnica permette di allineare sulla stessa riga sia il timestamp della scommessa attuale sia quello della scommessa immediatamente precedente.
- **Calcolo Esplicito dell'Intervallo:** È stata calcolata la differenza algebrica tra le due date. Il risultato transitorio è stato prima convertito in secondi totali e poi diviso per 60, ottenendo una misurazione continua standardizzata in **minuti** (`time_diff_minutes`).
- **Pulizia e Ottimizzazione:** Le colonne di appoggio generate per il calcolo (`prev_datetime` e `time_diff`) sono state rimosse per preservare l'efficienza della memoria prima di invocare il rendering grafico.
- **Scelte di Visualizzazione (Istogramma Logaritmico):** Si è optato per una griglia verticale di tre istogrammi (uno per ciascun indirizzo top 3). Poiché ci si aspetta una distribuzione con una fortissima asimmetria positiva, l'asse Y è stato impostato su una **scala logaritmica**. In assenza di questa scala, le frequenze minori sarebbero state del tutto schiacciate e illeggibili.
- **Filtraggio e Formattazione dell'Asse X:** Per evitare che *outlier* con ore o giorni di distanza distorcessero la finestra di osservazione, il grafico è stato limitato a un tetto massimo di 90 minuti (`limit_minutes=90`).

Intervallo tra Bet Consecutive (Scala Y Logaritmica)



Osservazioni e Risultati:

L'analisi visiva degli istogrammi svela in modo inequivocabile la vera natura del traffico generato sui tre indirizzi principali di Satoshi Dice. Tutti e tre i grafici presentano una distribuzione identica, caratterizzata da un'asimmetria estrema.

Dalla lettura dei dati emergono le seguenti conclusioni analitiche:

1. **Il Dominio del Singolo Minuto (Spike Iniziale):** La caratteristica visiva preponderante è l'enorme colonna in corrispondenza del primissimo *bin* (0-1 minuto). Ricordando che l'asse Y utilizza una scala logaritmica, questo significa che la stragrande maggioranza delle giocate consecutive (parliamo di milioni di istanze nel caso di `less than 32000`) è avvenuta a distanza pochi secondi l'una dall'altra.
2. **Forte Indizio di utilizzo di bot:** Una concentrazione così massiccia di scommesse sub-minuto non è compatibile con il normale comportamento umano (che richiederebbe il tempo fisico di attendere l'esito visivo, costruire una nuova transazione sul wallet, firmarla e trasmetterla). Questo dato suggerisce in modo schiacciante che la gran parte dei volumi di Satoshi Dice fosse generata da script o **bot automatizzati**, programmati per giocare a ripetizione e ad altissima frequenza.
3. **Decadimento (Traffico Organico):** Superato il picco del primo minuto, il conteggio crolla verticalmente di svariati ordini di grandezza, per poi assestarsi su un lento e regolare decadimento lungo tutto l'arco dei 90 minuti. Questa lunga "coda" rappresenta verosimilmente il traffico organico generato dai giocatori umani e occasionali, i quali piazzavano scommesse a intervalli più ampi.

In sintesi, si delinea il quadro di un ecosistema dominato dal gioco algoritmico ad alta frequenza, in cui i bot potevano scommettere, vincere e reinvestire i fondi in un ciclo quasi istantaneo.


8. Analisi delle sequenze di bet (Scelte Tecniche)

Il quinto obiettivo del progetto introduce la *Network Analysis* per studiare le sequenze di scommesse (catene), focalizzandosi sull'indirizzo più popolare. Per garantire che le catene siano lineari e prive di ambiguità, l'analisi è stata ristretta al sottoinsieme delle **"simple bet"**.

Il processo di estrazione e la modellazione del grafo sono stati implementati seguendo questi passaggi algoritmici:

- **Filtraggio Strutturale (Isolamento delle Simple Bet):** Per prima cosa, sono state calcolate le frequenze di input e output per l'intero dataset. Sono state mantenute esclusivamente le transazioni caratterizzate da esattamente 1 input e 2 output.
- **Identificazione dell'Output di Resto (Change Address):** Delle transazioni così filtrate, sono state estrapolate solo quelle in cui uno dei due output era destinato all'indirizzo target di Satoshi Dice. Il secondo output di queste transazioni è stato classificato come **indirizzo di resto**.
- **Tracciamento dei Collegamenti Logici (Generazione degli Archi):** Per trovare i collegamenti consecutivi, la tabella degli output di resto è stata unita in *inner join* con la tabella `inputs` (effettuando il matching su `txId == prevTxId` e `position == prevTxpos`). Il risultato è stato ulteriormente filtrato per assicurarsi che anche la transazione di destinazione rientrasse nella categoria *simple bet*.

- **Costruzione del Grafo Diretto:** Utilizzando la libreria **NetworkX**, è stato inizializzato un grafo diretto $G = (V, E)$. Ogni identificativo di transazione (`txId`) è stato aggiunto come nodo V , mentre i collegamenti trovati nel passaggio precedente sono diventati gli archi orientati E . L'ID dell'indirizzo di resto è stato salvato come attributo dell'arco, garantendo la tracciabilità richiesta.
- **Analisi dei Cammini (Weakly Connected Components):** L'architettura stessa del sistema (in-degree e out-degree massimi pari a 1) forza il grafo a presentarsi come un insieme di cammini disgiunti. Sfruttando l'algoritmo di individuazione delle *weakly connected components* di NetworkX, sono state isolate le singole catene, conteggiando il numero di nodi (transazioni) per ciascuna di esse.
- **Visualizzazione Grafica:** La distribuzione delle lunghezze presenta un'asimmetria estrema. Per rappresentarla in modo esaustivo, si è optato per un duplice approccio grafico. A sinistra è stato tracciato un istogramma su scala lineare (limitato visivamente per non schiacciare i dati) per analizzare la concentrazione della massa principale. A destra, l'intero dataset è stato mappato su uno scatterplot in scala bi-logaritmica (Log-Log), strumento statistico per lo studio delle reti complesse al fine di verificare la presenza di distribuzioni a coda lunga.



Osservazioni e Risultati: Distribuzione delle Catene

Dalla lettura del grafico e dei dati estratti emergono le seguenti evidenze tecniche:

1. **Dominanza delle Sessioni Brevi (Traffico Organico):** Come evidenziato dall'istogramma lineare a sinistra, la stragrande maggioranza delle catene si estingue in tempi rapidissimi. L'altissima concentrazione in prossimità dell'origine (con una mediana di sole 3 scommesse) suggerisce che l'interazione tipica del giocatore medio umano con la piattaforma fosse altamente episodica e limitata a pochissime giocate consecutive.
2. **Evidenza Matematica della Power Law (La Coda Lunga):** L'osservazione dello scatterplot Log-Log a destra rivela la vera natura dell'ecosistema. Mappando le

frequenze su scala bi-logaritmica, i punti si allineano disegnando una retta decrescente. Questo andamento diagonale è la firma matematica di una *Legge di Potenza (Power Law)*, indicando che la rete non segue una distribuzione casuale normale, ma possiede un'architettura gerarchica dominata da "super-nodi" o "hub" capaci di generare catene lunghissime (fino a un picco massimo registrato di 717 transazioni).

3. **Profilazione Comportamentale (Bot vs Umani):** L'esistenza di questa coda lunga obbediente a una Power Law certifica la presenza di due profili d'uso nettamente distinti. Dal grafico emerge chiaramente che, oltre alla massa di giocatori occasionali, operava un gruppo ristretto di entità che giocava in modo continuo e massiccio. Sequenze ininterrotte di centinaia di transazioni confermano, in linea con le analisi temporali precedenti, l'uso intensivo di script e bot automatizzati per il gioco ad alta frequenza, e non di utenti umani.

9. De-anonimizzazione delle Catene tramite Web Scraping (Scelte Tecniche)

L'ultima fase dell'analisi di rete consiste nell'estrarre le catene di transazioni più lunghe presenti nel grafo e tentare di de-anonimizzare gli indirizzi coinvolti interrogando il servizio pubblico **WalletExplorer.com**. L'obiettivo è verificare se queste lunghe sequenze di nodi siano riconducibili a singole entità, per automatizzare questa indagine in modo efficiente e invisibile ai sistemi anti-bot, l'approccio è stato il seguente:

- **Estrazione e mapping degli indirizzi:** Tramite la funzione `nx.weakly_connected_components`, il grafo è stato scomposto nelle sue catene isolate, ordinandole in modo decrescente per selezionare solo le prime `h` (le più lunghe). Successivamente, gli identificativi numerici dei nodi (`addressId`) sono stati incrociati con il dataset originale per recuperare gli hash crittografici reali, escludendo a priori gli indirizzi fittizi, contrassegnati dal prefisso `#`.
- **Configurazioni di scraping:** Per interrogare la piattaforma senza incorrere in blocchi, come gli errori HTTP 403 o 429, è stato configurato un bot con **Chrome WebDriver**. È stata usata la libreria `fake_useragent` per camuffare l'impronta del browser a ogni avvio, unita al flag `--disable-blink-features=AutomationControlled` per nascondere la natura automatizzata dello script. L'opzione `--headless=new` ha garantito l'esecuzione silenziosa in background.
- **Simulazione del comportamento umano:** Anziché interrogare direttamente gli URL, lo script naviga sulla homepage del sito, individua dinamicamente la barra di ricerca tramite l'attributo `name="q"`, vi digita l'hash e simula la pressione del tasto `INVIO` (`Keys.RETURN`), replicando l'esatta interazione di un utente reale.
- **Gestione dell'overhead:** Poiché uno stesso indirizzo può comparire in molteplici

archi all'interno della stessa catena o in catene diverse, è stato implementato un dizionario di cache locale (`wallet_cache`). Il bot interroga la rete solo se l'hash è del tutto nuovo, riducendo drasticamente il numero di richieste HTTP, accelerando l'esecuzione globale.

Inizia lo scraping delle catene

Analisi Chain_1 - (716 indirizzi validi)

Analisi Chain_2 - (441 indirizzi validi)

Analisi Chain_3 - (351 indirizzi validi)

Analisi Chain_4 - (292 indirizzi validi)

Analisi Chain_5 - (272 indirizzi validi)

Analisi Chain_6 - (245 indirizzi validi)

Analisi Chain_7 - (242 indirizzi validi)

Analisi Chain_8 - (234 indirizzi validi)

Analisi Chain_9 - (232 indirizzi validi)

Analisi Chain_10 - (228 indirizzi validi)

Scraping Completato! Ecco la tabella finale:

	ID Catena	Lunghezza Catena	Tot Indirizzi Analizzati	Wallet Distinti	% Wallet Predominante	ID Wallet Predominante
0	Chain_1	716	716	76	50.14%	[0025d633f8]
1	Chain_2	441	441	1	100.00%	[00002c4379]
2	Chain_3	351	351	5	79.20%	[0025d633f8]
3	Chain_4	292	292	5	75.68%	[000f35cb33]
4	Chain_5	272	272	2	99.63%	[000305c34c]
5	Chain_6	245	245	20	54.29%	[001b861dc5]
6	Chain_7	242	242	25	71.90%	[004bf37491]
7	Chain_8	234	234	11	88.03%	[0005f727db]
8	Chain_9	232	232	3	93.97%	[0012ea9acf]
9	Chain_10	228	228	36	78.51%	[0012ea9acf]

Osservazioni e Risultati

L'esame della tabella dei risultati, generata sui dati estratti dalle 10 catene più lunghe del grafo, offre uno spaccato fondamentale sulle dinamiche di aggregazione dei fondi e sul comportamento delle entità nella rete Bitcoin. Dalla lettura dei dati emergono le seguenti evidenze analitiche:

- **L'eccezione dell'entità singola (Chain_2):** La seconda catena più lunga del dataset spicca per la sua totale centralizzazione. Su ben 441 indirizzi analizzati, è stato rilevato un solo wallet distinto ([00002c4379]), portando la percentuale di predominanza al **100.00%**. Questa topologia è il caso di un'unica macro-entità che muove i fondi internamente senza mai interagire con utenti esterni.
- **Predominanza quasi-totale in catene frammentate:** Anche in catene composte da più wallet, l'analisi rivela che queste sono governate di fatto da un singolo attore. Il caso più evidente è la Chain_5 , dove il wallet predominante controlla il **99.63%** dei 272 nodi, o la Chain_9 (93.97% di predominanza).
- **Ricorrenza di entità dominanti :** Osservando gli ID dei wallet, emerge come singole entità monopolizzino più catene contemporaneamente. Il wallet [0025d633f8] domina sia la catena più lunga (Chain_1) sia la terza (Chain_3); similmente, il wallet [0012ea9acf] controlla sia la Chain_9 che la Chain_10 . I picchi di attività sulla rete non sono quindi casuali, ma derivano dalle operazioni continue di pochissime entità.
- **Rapporto inverso tra complessità e predominanza:** La catena più lunga in assoluto (Chain_1 , 716 indirizzi) presenta paradossalmente il tasso di predominanza più basso della matrice (50.14%) e la massima dispersione (76 wallet distinti). Catene più corte mostrano invece un forte accentramento. Ciò dimostra che quando una sequenza di transazioni si allunga oltre una certa soglia, si interseca inevitabilmente con l'economia reale e con servizi di terze parti, frammentando la tracciabilità.